

NNDL Project 2 Report

CIFAR-10 Classification and Batch Normalization

于翔 23307130202

June 2026

摘要

本项目围绕 CIFAR-10 图像分类完成两部分实验。第一部分设计并训练一个面向 32×32 图像的残差卷积网络，系统比较网络宽度、激活函数、优化器、损失函数和正则化强度对测试精度的影响。最终发布的 Part 1 checkpoint 采用中等宽度 CifarResNet，在 200 epoch 训练中取得 96.59% 的最佳测试精度；消融实验中 large-width 配置在 100 epoch 下达到 96.85%，显示模型容量仍是主要可提升方向。第二部分复现 VGG-A 与 VGG-A+BatchNorm 的对比，并通过多学习率训练轨迹和 loss landscape band 解释 BN 对训练稳定性的贡献。100 epoch 对比中，VGG-A+BN 达到 90.52%，相比 VGG-A 的 87.61% 提升 2.91 个百分点。

1 Submission Links and Reproducibility

表 1: Required submission links and released artifacts.

Item	Link or Path
Code repository	https://github.com/Parry-Git/Deep-Learning-Project2
Dataset and trained weights	https://www.modelscope.cn/models/ParryY/Deep-Learning-Project2
Part 1 released checkpoint	checkpoints/part1_best.pth
Part 2 released checkpoints	checkpoints/vgg_bn/best_vgg_compare_e100_*.pth

表 2: Coverage of the project requirements.

Requirement	Where it is addressed
Identity and links	Title page and Table 1.
Part 1 modules	CifarResNet uses Conv2d, activation, global average pooling, fully connected layer, BatchNorm, Dropout, and residual shortcuts.
Part 1 ablations	Table 4 compares width/filter counts, activations, optimizers, losses, and regularization.
Visualization and insight	Training curves, qualitative predictions, and ablation analysis in Section 2.
BN comparison	VGG-A and VGG-A+BN training curves and accuracy table in Section 3.1.
Loss landscape	Learning-rate sweep and loss landscape band analysis in Sections 3.2–3.3.

所有实验均在同一份 CIFAR-10 数据集上完成，训练集 50,000 张、测试集 10,000 张。代码仓库只保存源码、报告和复现实验脚本；数据集、训练日志、曲线图和模型权重不进入 Git，而是通过 ModelScope 发布。这样可以保持 GitHub 仓库轻量，同时保证评测者可以通过如下命令下载数据与发布权重，并复现核心测试：

```
conda activate sii
pip install -r requirements.txt
python codes/download.py --all
python codes/part1_cifar10/test.py
```

若需要从头复现实验，可进一步运行 Part 1 主训练、Part 1 消融脚本和 Part 2 批处理脚本，具体命令见 GitHub README。核心依赖保持为 PyTorch、torchvision、matplotlib、numpy 和 modelscope，避免引入不必要的环境复杂度。

2 Part 1: CIFAR-10 Classifier

2.1 Architecture

Part 1 使用自定义 `CifarResNet`，而不是直接调用 `torchvision` 中的现成分类器。网络包含项目要求的 Conv2d、Pooling、Activation 和 Fully Connected 层，同时引入 BatchNorm、Dropout 和 residual connection 作为稳定训练与提升泛化的组件。基础结构如下：

$$\begin{aligned} \text{Conv}_{3 \times 3}(3 \rightarrow C_1) &\rightarrow [\text{ResidualBlock}]_{C_1}^3 \rightarrow [\text{ResidualBlock}]_{C_2}^3 \\ &\rightarrow [\text{ResidualBlock}]_{C_3}^3 \rightarrow \text{GAP} \rightarrow \text{FC}_{10}. \end{aligned}$$

每个 residual block 含两个 3×3 卷积、两个 BatchNorm、一个可选 Dropout2d 和 shortcut 分支；阶段切换时通过 stride=2 下采样。最终采用 global average pooling 替代大规模全连接层，

以减少参数量并提升平移鲁棒性。主模型配置为 channels (64, 128, 256)、blocks (3, 3, 3)、ReLU、dropout 0.1，约 4.33M 参数。

2.2 Training Setup

训练数据增强包括 RandomCrop(32, padding=4)、RandomHorizontalFlip、标准 CIFAR-10 归一化和 Cutout(length=16)。优化器采用 SGD momentum 0.9，初始学习率 0.1，weight decay 5×10^{-4} ；学习率调度为 5 epoch warmup 后接 CosineAnnealing。损失函数默认使用 label smoothing cross entropy，平滑系数为 0.1。训练默认开启 AMP，在 CUDA 上使用 float16 autocast 和 GradScaler；它主要降低训练时间和显存占用，未改变模型结构或评价流程。

表 3: Part 1 main run configuration and result.

Item	Value
Model	CifarResNet, blocks (3, 3, 3), channels (64, 128, 256)
Optimizer	SGD, momentum 0.9, weight decay 5×10^{-4}
Loss	Cross entropy with label smoothing 0.1
Scheduler	5-epoch warmup + cosine annealing
Epochs / batch size	200 / 128
Best test accuracy	96.59% at epoch 195
Final test accuracy	96.52%




图 1: Training and test curves of the released Part 1 model.

2.3 Ablation Study

为避免单个超参数结论被其它因素混淆，消融实验均以相同的数据增强、batch size、100 epoch、cosine schedule 和默认 AMP 为基础，只改变一组变量。表 4 汇总了所有 Part 1 消融实验。

表 4: Part 1 ablation results on CIFAR-10.

Group	Variant	Main changed setting	Optimizer/Loss	Best Acc.	Final Acc.
Width	Small	channels (32, 64, 128)	SGD / LS 0.1	94.67	94.48
Width	Medium	channels (64, 128, 256)	SGD / LS 0.1	96.30	96.29
Width	Large	channels (128, 256, 512)	SGD / LS 0.1	96.85	96.77
Activation	ReLU	activation=ReLU	SGD / LS 0.1	96.28	96.24
Activation	GELU	activation=GELU	SGD / LS 0.1	95.71	95.62
Activation	SiLU	activation=SiLU	SGD / LS 0.1	95.12	95.09
Optimizer	SGD	lr=0.1	LS 0.1	96.15	96.09
Optimizer	Adam	lr=0.001	LS 0.1	95.23	95.06
Optimizer	AdamW	lr=0.001	LS 0.1	95.26	95.21
Loss	CE	label smoothing=0	SGD	96.10	96.03
Loss	LS 0.05	label smoothing=0.05	SGD	96.39	96.35
Loss	LS 0.10	label smoothing=0.10	SGD	96.33	96.33
Loss	Focal	$\gamma = 2.0$	SGD	95.52	95.46
Reg.	Dropout 0.0	dropout=0.0	SGD / LS 0.1	96.28	96.22
Reg.	Dropout 0.1	dropout=0.1	SGD / LS 0.1	96.12	96.07
Reg.	Dropout 0.2	dropout=0.2	SGD / LS 0.1	95.83	95.76
Reg.	WD 10^{-4}	weight decay= 10^{-4}	SGD / LS 0.1	95.80	95.69

主要结论如下。第一，网络宽度是最明显的性能因素：从 small 到 medium 提升 1.63 个百分点，从 medium 到 large 进一步提升 0.55 个百分点。这说明当前误差仍有一部分来自模型容量限制，但 large-width 的计算和存储成本也显著增加，因此发布权重选择了更均衡的 medium-width 200 epoch 模型。第二，在本网络和训练设置下，ReLU 优于 GELU 和 SiLU。这并不说明 ReLU 总是更好，而是说明当前残差块、BatchNorm 和 Kaiming 初始化与 ReLU 匹配更直接，训练到 100 epoch 时泛化更稳定。第三，SGD+momentum 明显优于 Adam/AdamW；Adam 系列前期收敛快，但最终测试精度低约 0.9 个百分点，符合图像分类中 SGD 往往具有更好泛化的经验。第四，适度 label smoothing 有帮助，其中 0.05 略优于 0.10；focal loss 在类别均衡的 CIFAR-10 上没有优势。第五，Dropout 并非越大越好。当前模型已有数据增强、weight decay、BatchNorm 和残差结构，dropout 0.2 会产生欠拟合倾向。




图 2: Qualitative predictions from the released Part 1 checkpoint.

3 Part 2: Batch Normalization

3.1 VGG-A and VGG-A+BN Setup

Part 2 使用 VGG-A 作为 baseline,并在每个卷积层之后加入 BatchNorm2d 构成 VGG-A+BN。两者除 BN 之外保持一致: 5 个卷积 stage、MaxPool 下采样、三层 classifier, 输入分辨率仍为 CIFAR-10 的 32×32 。VGG-A 有 9,750,922 个参数, VGG-A+BN 有 9,753,674 个参数; 参数量差异很小, 因此性能差异主要来自 BN 的优化效果, 而不是容量。

表 5: VGG-A vs VGG-A+BN, 100 epochs, Adam lr= 10^{-3} .

Model	Params	Best Acc.	Best Epoch	Final Acc.
VGG-A	9,750,922	87.61	99	86.58
VGG-A+BN	9,753,674	90.52	98	90.30




图 3: Training curves for VGG-A and VGG-A+BN. BN improves both convergence and final accuracy.

从曲线可以看出, VGG-A+BN 在训练早期更快进入有效下降区间, 测试精度曲线也更加平滑。在 100 epoch 结束时, BN 版本 final accuracy 为 90.30%, 而无 BN 的 VGG-A 为 86.58%。这说明 BN 不只是提高最终精度, 也改善了训练过程的可控性。

3.2 Learning Rate Sensitivity

为了进一步检查 BN 的稳定性, 实验在 $\{10^{-4}, 5 \times 10^{-4}, 10^{-3}, 2 \times 10^{-3}\}$ 四个学习率下分别训练 40 epoch。结果如表 6 所示。

表 6: Learning-rate sweep for VGG-A and VGG-A+BN.

Learning rate	VGG-A Best	VGG-A Final	VGG-A+BN Best	VGG-A+BN Final
1×10^{-4}	85.14	84.30	86.24	85.97
5×10^{-4}	86.51	86.39	89.54	89.54
1×10^{-3}	83.68	83.44	89.46	89.46
2×10^{-3}	76.64	75.45	89.38	89.02

无 BN 的 VGG-A 对学习率非常敏感: 当 lr 从 5×10^{-4} 增加到 2×10^{-3} 时, best accuracy 从 86.51% 降到 76.64%。相反, VGG-A+BN 在后三个学习率下都稳定在约 89.4% 左右。这支持了 BN 能扩大可用学习率区间、降低调参敏感性的结论。




图 4: VGG learning-rate sweep curves. BN keeps the curves stable under larger learning rates.

3.3 Loss Landscape

Loss landscape 实验记录四个学习率下每个模型的 mini-batch loss, 并对同一步的多条 loss 曲线取上下界, 形成 “band”。band 越宽, 说明同一训练阶段对学习率越敏感; 最终平均 loss 越低, 说明对应设置更容易到达有效优化区域。

表 7: Loss landscape band statistics.

Model	Mean Band Width	Max Band Width	Final Mean Loss
VGG-A	0.7475	18.0730	2.0057
VGG-A+BN	1.3808	5.7247	1.3629




图 5: Loss landscape bands across learning rates. BN substantially lowers final mean loss and avoids the extreme loss spike observed without BN.

虽然 BN 的平均 band width 更大, 但其最大 band width 只有 VGG-A 的约三分之一, 且最终平均 loss 明显更低。结合学习率 sweep 可知, 无 BN 模型在部分学习率下会出现剧烈损失峰值并最终停在较差区域; BN 通过规范化中间激活, 缓解了层间尺度漂移, 使梯度更新在更宽的学习率范围内保持有效。

4 Discussion

Part 1 的结果表明, 在 CIFAR-10 这类小尺寸图像任务上, 一个专门设计的残差 CNN 可以在不依赖预训练模型的情况下达到 96% 以上测试精度。最有效的因素是足够的卷积宽度、SGD + momentum、cosine schedule 和适度 label smoothing。相较之下, 更复杂的激活函数和 focal loss 没有带来收益, 说明模型改进需要结合数据分布和优化设置, 而不是简单堆叠技巧。

Part 2 的结果清楚显示 BN 的价值主要体现在优化稳定性上。VGG-A 与 VGG-A+BN 参数量几乎相同, 但 BN 版本在主实验中高 2.91 个百分点, 在高学习率设置下优势扩大到十几个百分点。loss landscape 进一步说明, BN 减少了极端 loss spike, 并使模型更容易到达低损失区域。

当前仍有两个可改进点。第一, large-width Part 1 消融达到 96.85%, 超过发布的 medium-width checkpoint; 如果最终目标是单纯追求最高准确率, 可以额外训练并发布 large-width 200 epoch 权重。第二, 当前 Part 2 的目标是分析 BN 的优化作用, 而不是超过 Part 1 的专用残差分类器; 因此 VGG-A+BN 精度低于 CifarResNet 是符合预期的。

5 Conclusion

本项目完成了 CIFAR-10 自定义 CNN 训练、系统消融实验、VGG-A BatchNorm 对比实验以及 loss landscape 分析。Part 1 发布模型达到 96.59%, 消融实验最高观察精度为 96.85%; Part 2 中 VGG-A+BN 达到 90.52%, 明显优于无 BN baseline。整体实验结果相互支撑: 残差结构、合

适正则化和稳健优化策略决定最终分类性能，而 BatchNorm 的核心作用是改善优化条件、扩大稳定学习率范围并降低训练失败风险。