

Neural Network and Deep Learning Project 2 Report

CIFAR-10 Classification and Batch Normalization

于翔 23307130202

June 2026

摘要

本项目围绕 CIFAR-10 图像分类完成两部分实验。第一部分设计并训练残差卷积网络，系统比较网络宽度、激活函数、优化器、损失函数和正则化强度对测试精度的影响。最终的 Part 1 best checkpoint 采用中等宽度 CifarResNet，在 200 epoch 训练中取得 96.59% 的最佳测试精度；消融实验中 large-width 配置在 100 epoch 下达到 96.85%，显示模型容量仍是主要可提升方向。第二部分复现 VGG-A 与 VGG-A+BatchNorm 的对比，并通过多学习率训练轨迹和 loss landscape band 解释 BN 对训练稳定性的贡献。100 epoch 对比中，VGG-A+BN 达到 90.52%，相比 VGG-A 的 87.61% 提升 2.91 个百分点。

1 Submission Links and Reproducibility

表 1: Required submission links and checkpoint artifacts.

Item	Link or Path
Code repository	https://github.com/Parry-Git/Deep-Learning-Project2
Dataset and trained weights	https://www.modelscope.cn/models/ParryY/Deep-Learning-Project2
Part 1 best checkpoint	checkpoints/part1_best.pth
Part 2 comparison checkpoints	checkpoints/vgg_bn/best_vgg_compare_e100_*.pth

所有实验均在 CIFAR-10 数据集上完成，训练集 50,000 张、测试集 10,000 张。代码仓库保存源码、报告和复现实验脚本；数据集、训练日志、曲线图和模型权重通过 ModelScope 保存。可以通过如下命令下载数据与 best checkpoints，并复现核心测试：

```
pip install -r requirements.txt
python codes/download.py --all
python codes/part1_cifar10/test.py
```

若需要从头复现实验，可进一步运行 Part 1 主训练、Part 1 消融脚本和 Part 2 批处理脚本，具体命令见 README，环境参考 requirements。

2 Part 1: CIFAR-10 Classifier

2.1 Architecture

Part 1 使用自定义 CifarResNet，而不是直接调用 torchvision 中的现成分类器。网络包含项目要求的 Conv2d、Pooling、Activation 和 Fully Connected 层，同时引入 BatchNorm、Dropout 和 residual connection 作为稳定训练与提升泛化的组件。基础结构如下：

$$\text{Conv}_{3 \times 3}(3 \rightarrow C_1) \rightarrow [\text{ResidualBlock}]_{C_1}^3 \rightarrow [\text{ResidualBlock}]_{C_2}^3 \\ \rightarrow [\text{ResidualBlock}]_{C_3}^3 \rightarrow \text{GAP} \rightarrow \text{FC}_{10}.$$

每个 residual block 含两个 3×3 卷积、两个 BatchNorm、一个可选 Dropout2d 和 shortcut 分支；阶段切换时通过 stride=2 下采样。最终采用 global average pooling 替代大规模全连接层，以减少参数量并提升平移鲁棒性。主模型配置为 channels (64, 128, 256)、blocks (3, 3, 3)、ReLU、dropout 0.1，约 4.33M 参数。

表 2: CifarResNet architecture used for the selected Part 1 best checkpoint.

Stage	Operator	Output Size	Notes
Input	CIFAR-10 image	$3 \times 32 \times 32$	normalized RGB image
Stem	3×3 Conv, BN, ReLU	$64 \times 32 \times 32$	no spatial downsampling
Stage 1	3 residual blocks	$64 \times 32 \times 32$	stride 1
Stage 2	3 residual blocks	$128 \times 16 \times 16$	first block stride 2
Stage 3	3 residual blocks	$256 \times 8 \times 8$	first block stride 2
Pooling	Global average pooling	256	average over 8×8 map
Classifier	Linear layer	10	CIFAR-10 logits

对于输入 feature map x ，块内计算可以写成

$$h_1 = \phi(\text{BN}_1(W_1 * x)), \\ h_2 = \text{BN}_2(W_2 * \text{Dropout}(h_1)), \\ y = \phi(h_2 + S(x)),$$

其中 $*$ 表示卷积， ϕ 是激活函数， $S(x)$ 是 identity shortcut；当通道数或空间尺寸变化时， $S(x)$ 由 1×1 卷积和 BatchNorm 实现。这个形式让主分支只需学习残差修正项，而不是完整的输入到输出映射，因此深一些的网络仍然比较容易优化。全局平均池化层的第 c 个输出为

$$z_c = \frac{1}{HW} \sum_{i=1}^H \sum_{j=1}^W x_{cij},$$

它把空间维度压缩为每个通道的响应强度，减少 classifier 参数量并降低过拟合风险。

2.2 Training Setup

训练数据增强包括 RandomCrop(32, padding=4)、RandomHorizontalFlip、标准 CIFAR-10 归一化和 Cutout(length=16)。优化器采用 SGD momentum 0.9，初始学习率 0.1，weight decay

5×10^{-4} ；学习率调度为 5 epoch warmup 后接 CosineAnnealing。损失函数默认使用 label smoothing cross entropy，平滑系数为 0.1。训练默认开启 AMP，在 CUDA 上使用 float16 autocast 和 GradScaler；它主要降低训练时间和显存占用，未改变模型结构或评价流程。

训练目标由分类损失和权重衰减组成：

$$\mathcal{J}(\theta) = \frac{1}{N} \sum_{n=1}^N \mathcal{L}(f_{\theta}(x_n), y_n) + \frac{\lambda}{2} \|\theta\|_2^2,$$

其中 $\lambda = 5 \times 10^{-4}$ 。默认损失采用 label smoothing。设类别数为 $K = 10$ ，真实类别为 y ，平滑系数为 ε ，则目标分布为

$$q_k = \begin{cases} 1 - \varepsilon + \varepsilon/K, & k = y, \\ \varepsilon/K, & k \neq y, \end{cases} \quad \mathcal{L}_{\text{LS}} = - \sum_{k=1}^K q_k \log p_k.$$

相比 hard one-hot label，它降低了模型对单一类别的过度自信。消融实验中的 focal loss 使用

$$\mathcal{L}_{\text{focal}} = -(1 - p_y)^{\gamma} \log p_y, \quad \gamma = 2,$$

但在 CIFAR-10 这种类别均衡数据上并没有优于交叉熵。

学习率采用 warmup 后的余弦退火。warmup 结束后的第 t 个 epoch 的学习率可写为

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos \frac{\pi t}{T} \right),$$

其中 $\eta_{\max} = 0.1$ ， $\eta_{\min} = 10^{-6}$ 。这个调度在前期保证足够大的探索步长，后期逐步减小更新幅度，因此测试曲线在训练后半段更加稳定。

表 3: Part 1 main run configuration and result.

Item	Value
Model	CifarResNet, blocks (3, 3, 3), channels (64, 128, 256)
Optimizer	SGD, momentum 0.9, weight decay 5×10^{-4}
Loss	Cross entropy with label smoothing 0.1
Scheduler	5-epoch warmup + cosine annealing
Epochs / batch size	200 / 128
Best test accuracy	96.59% at epoch 195
Final test accuracy	96.52%




图 1: Training and test curves of the Part 1 best-checkpoint run.

2.3 Ablation Study

为避免单个超参数结论被其它因素混淆, 消融实验均以相同的数据增强、batch size、100 epoch、cosine schedule 和默认 AMP 为基础, 只改变一组变量。表 4 汇总了所有 Part 1 消融实验。

表 4: Part 1 ablation results on CIFAR-10.

Group	Variant	Main changed setting	Optimizer/Loss	Best Acc.	Final Acc.
Width	Small	channels (32, 64, 128)	SGD / LS 0.1	94.67	94.48
Width	Medium	channels (64, 128, 256)	SGD / LS 0.1	96.30	96.29
Width	Large	channels (128, 256, 512)	SGD / LS 0.1	96.85	96.77
Activation	ReLU	activation=ReLU	SGD / LS 0.1	96.28	96.24
Activation	GELU	activation=GELU	SGD / LS 0.1	95.71	95.62
Activation	SiLU	activation=SiLU	SGD / LS 0.1	95.12	95.09
Optimizer	SGD	lr=0.1	LS 0.1	96.15	96.09
Optimizer	Adam	lr=0.001	LS 0.1	95.23	95.06
Optimizer	AdamW	lr=0.001	LS 0.1	95.26	95.21
Loss	CE	label smoothing=0	SGD	96.10	96.03
Loss	LS 0.05	label smoothing=0.05	SGD	96.39	96.35
Loss	LS 0.10	label smoothing=0.10	SGD	96.33	96.33
Loss	Focal	$\gamma = 2.0$	SGD	95.52	95.46
Reg.	Dropout 0.0	dropout=0.0	SGD / LS 0.1	96.28	96.22
Reg.	Dropout 0.1	dropout=0.1	SGD / LS 0.1	96.12	96.07
Reg.	Dropout 0.2	dropout=0.2	SGD / LS 0.1	95.83	95.76
Reg.	WD 10^{-4}	weight decay= 10^{-4}	SGD / LS 0.1	95.80	95.69

主要结论如下。第一, 网络宽度是最明显的性能因素: 从 small 到 medium 提升 1.63 个百分点, 从 medium 到 large 进一步提升 0.55 个百分点。这说明当前误差仍有一部分来自模型容量限制, 但 large-width 的计算和存储成本也显著增加, 因此最终 checkpoint 选择了更均衡的 medium-width 200 epoch 模型。第二, 在本网络和训练设置下, ReLU 优于 GELU 和 SiLU。这并不说明 ReLU 总是更好, 而是说明当前残差块、BatchNorm 和 Kaiming 初始化与 ReLU 匹配更直接, 训练到 100 epoch 时泛化更稳定。第三, SGD+momentum 明显优于 Adam/AdamW; Adam 系列前期收敛快, 但最终测试精度低约 0.9 个百分点, 符合图像分类中 SGD 往往具有更好泛化的经验。第四,

适度 label smoothing 有帮助，其中 0.05 略优于 0.10；focal loss 在类别均衡的 CIFAR-10 上没有优势。第五，Dropout 并非越大越好。当前模型已有数据增强、weight decay、BatchNorm 和残差结构，dropout 0.2 会产生欠拟合倾向。




图 2: Qualitative predictions from the Part 1 best checkpoint.

2.4 Network Interpretation

为了揭示网络学到的内部表征，我们从三个角度进行可视化分析：第一层卷积滤波器、中间层特征图演变以及 Grad-CAM [3] 类激活映射。

2.4.1 First-layer Filter Visualization

图 3 展示了 CifarResNet 第一层 64 个 3×3 卷积核的可视化。每个 filter 的三通道权重被归一化到 $[0, 1]$ 后以 RGB 显示。可以观察到不同滤波器捕获了不同方向的颜色梯度和边缘模式：部分 filter 呈现水平或垂直条纹，对应边缘检测；部分呈现对角线或颜色对比模式，对应纹理特征。这与经典 CNN 理论一致——浅层学习低级视觉特征，为后续层的高级语义表征提供基础。




图 3: First-layer 3×3 convolution filters of CifarResNet. Each cell shows one filter's RGB weights normalized to $[0, 1]$. Diverse edge and color patterns are visible.

2.4.2 Feature Map Evolution

图 4 展示了一张测试图像在网络各阶段的前 16 个通道特征图。从 stem 层到 stage 3，特征图的空间分辨率逐步降低 ($32 \times 32 \rightarrow 16 \times 16 \rightarrow 8 \times 8$)，而通道数增加 ($64 \rightarrow 128 \rightarrow 256$)。浅层特征图保留了较多的空间细节和边缘信息；深层特征图的激活更加稀疏和语义化，每个通道倾向于响应特定的高层概念（如物体的轮廓或纹理区域），验证了残差网络逐层抽象的特征提取过程。




图 4: Feature map evolution across network stages. From stem to stage 3, spatial resolution decreases while semantic abstraction increases.

2.4.3 Grad-CAM Analysis

Grad-CAM 通过计算目标类别关于最后一个卷积层特征图的梯度，生成空间注意力热力图。对于预测类别 c ，最后卷积层的第 k 个通道权重为

$$\alpha_k^c = \frac{1}{HW} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k},$$

Grad-CAM 热力图定义为

$$L_{\text{Grad-CAM}}^c = \text{ReLU}\left(\sum_k \alpha_k^c A^k\right).$$

图 5 展示了 12 张测试样本的 Grad-CAM 结果。热力图清晰地覆盖在目标物体区域：例如 ship 的热力集中在船体，automobile 集中在车身轮廓，bird 集中在鸟的身体。这表明模型确实学到了基于目标物体的判别特征，而非依赖背景或无关纹理。对于少量预测置信度较低的样本（如遮挡严重或类内差异大的 cat），热力图也相应更分散，反映了模型不确定性与注意力分布的一致性。




图 5: Grad-CAM visualization on 12 test samples. Left: original image; right: Grad-CAM heatmap overlaid. The network consistently focuses on the target object rather than background.

3 Part 2: Batch Normalization

3.1 VGG-A and VGG-A+BN Setup

Part 2 使用 VGG-A 作为 baseline,并在每个卷积层之后加入 BatchNorm2d 构成 VGG-A+BN。两者除 BN 之外保持一致：5 个卷积 stage、MaxPool 下采样、三层 classifier，输入分辨率仍为 CIFAR-10 的 32×32 。VGG-A 有 9,750,922 个参数，VGG-A+BN 有 9,753,674 个参数；参数量差异很小，因此性能差异主要来自 BN 的优化效果，而不是容量。

对于一个 mini-batch 中的第 c 个通道，BatchNorm 的训练时计算为

$$\begin{aligned}\mu_c &= \frac{1}{mHW} \sum_{n=1}^m \sum_{i=1}^H \sum_{j=1}^W x_{ncij}, \\ \sigma_c^2 &= \frac{1}{mHW} \sum_{n=1}^m \sum_{i=1}^H \sum_{j=1}^W (x_{ncij} - \mu_c)^2, \\ \hat{x}_{ncij} &= \frac{x_{ncij} - \mu_c}{\sqrt{\sigma_c^2 + \epsilon}}, \\ y_{ncij} &= \gamma_c \hat{x}_{ncij} + \beta_c.\end{aligned}$$

其中 γ_c 和 β_c 是可学习的通道级仿射参数。BN 并不是简单限制表达能力；它在标准化后仍允许网络学习合适的尺度和偏移。

BN 原论文将其动机表述为缓解 internal covariate shift，并指出 mini-batch 归一化可以允许更高学习率、降低对初始化的敏感性，并在一些情况下提供正则化效果 [1]。后续 Santurkar 等人的研究进一步指出，BN 的有效性不应只理解为稳定中间层输入分布；更关键的是 BN 会让优化目标对参数扰动更加平滑，使 loss 和梯度变化更可预测，从而带来更稳定、更快速的训练 [2]。因此，本实验把 BN 的作用重点解释为改善优化条件：降低极端梯度/损失波动，扩大可用学习率范围，并减少训练失败风险。

表 5: VGG-A vs VGG-A+BN, 100 epochs, Adam lr= 10^{-3} .

Model	Params	Best Acc.	Best Epoch	Final Acc.
VGG-A	9,750,922	87.61	99	86.58
VGG-A+BN	9,753,674	90.52	98	90.30



图 6: Training curves for VGG-A and VGG-A+BN. BN improves both convergence and final accuracy.

从曲线可以看出，VGG-A+BN 在训练早期更快进入有效下降区间，测试精度曲线也更加平滑。在 100 epoch 结束时，BN 版本 final accuracy 为 90.30%，而无 BN 的 VGG-A 为 86.58%。这说明 BN 不只是提高最终精度，也改善了训练过程的可控性。

这里 VGG-A+BN 低于 Part 1 的 CifarResNet，VGG-A 没有 residual shortcut，优化难度高于残差网络；同时 Part 1 使用了更强的数据增强、label smoothing、SGD momentum 和 cosine schedule。因此，VGG-A 模型表现比 ResNet 较差，Part 2 主要说明 VGG-A 与 VGG-A+BN 的相对差异。

3.2 Learning Rate Sensitivity

为了进一步检查 BN 的稳定性，实验在 $\{10^{-4}, 5 \times 10^{-4}, 10^{-3}, 2 \times 10^{-3}\}$ 四个学习率下分别训练 40 epoch。结果如表 6 所示。

表 6: Learning-rate sweep for VGG-A and VGG-A+BN.

Learning rate	VGG-A Best	VGG-A Final	VGG-A+BN Best	VGG-A+BN Final
1×10^{-4}	85.14	84.30	86.24	85.97
5×10^{-4}	86.51	86.39	89.54	89.54
1×10^{-3}	83.68	83.44	89.46	89.46
2×10^{-3}	76.64	75.45	89.38	89.02

无 BN 的 VGG-A 对学习率非常敏感：当 lr 从 5×10^{-4} 增加到 2×10^{-3} 时，best accuracy 从 86.51% 降到 76.64%。相反，VGG-A+BN 在后三个学习率下都稳定在约 89.4% 左右。这与 BN 原论文中“可使用更高学习率”的经验结论一致 [1]，也与 Santurkar 等人关于 BN 让优化过程更稳定的解释一致 [2]。换言之，BN 的收益不仅体现在某一个学习率下的更高精度，还体现在学习率变化时性能退化更慢。




图 7: VGG learning-rate sweep curves. BN keeps the curves stable under larger learning rates.

3.3 Loss Landscape

Loss landscape 实验记录四个学习率下每个模型的逐 mini-batch training loss，并对同一歩的多条 loss 曲线取上下界，形成“band”。由于这里记录的是原始 per-step loss，而不是 epoch-average loss 或平滑后的 moving average，曲线在训练早期可能出现明显尖峰。band width 衡量的是不同学习率轨迹的分散程度，本身不等同于优化质量，因此需要结合最大尖峰、最终 loss 和学习率 sweep 的准确率分析。

更形式化地说，若训练目标为 $\mathcal{L}(\theta)$ ，优化景观的平滑性可用 loss 和梯度对参数扰动的敏感程度刻画。例如对相邻参数点 θ, θ' ，较小的

$$\frac{|\mathcal{L}(\theta') - \mathcal{L}(\theta)|}{\|\theta' - \theta\|_2} \quad \text{and} \quad \frac{\|\nabla \mathcal{L}(\theta') - \nabla \mathcal{L}(\theta)\|_2}{\|\theta' - \theta\|_2}$$

意味着 loss 和梯度对更新步长更不敏感。Santurkar 等正是从这一角度解释 BN: BN 使 loss landscape 更平滑, 梯度方向更可预测, 因此在较大学习率下也更不容易出现失控更新 [2]。本项目的 band 统计不是直接估计上述 Lipschitz 常数, 而是用多学习率训练轨迹给出一个经验侧面: 如果同一模型在不同学习率下出现巨大 loss spike, 则说明其优化过程对步长非常敏感。

记模型 M 在学习率 η_r 下第 t 个优化步的 mini-batch loss 为 $\ell_M^{(r)}(t)$ 。对同一个模型的多条学习率曲线, 定义

$$\ell_M^{\min}(t) = \min_r \ell_M^{(r)}(t), \quad \ell_M^{\max}(t) = \max_r \ell_M^{(r)}(t),$$

并用

$$w_M(t) = \ell_M^{\max}(t) - \ell_M^{\min}(t)$$

衡量第 t 步不同学习率训练轨迹的分散程度。图中的 shaded band 即 $[\ell_M^{\min}(t), \ell_M^{\max}(t)]$, 表中的 Mean/Max Band Width 分别对应 $w_M(t)$ 的均值和最大值。

表 7: Loss landscape band statistics.

Model	Mean Band Width	Max Band Width	Final Mean Loss
VGG-A	0.7475	18.0730	2.0057
VGG-A+BN	1.3808	5.7247	1.3629




图 8: Loss landscape bands across learning rates. The left panel keeps the full per-step loss range, while the right panel zooms in after the early transient. BN substantially lowers final mean loss and avoids the extreme early loss spike observed without BN.

左图中最明显的突增来自训练最早期的少数 step: step 1 基本对应随机初始化下的初始 loss, 约为 $\log 10$; 第一次参数更新后, 无 BN 的 VGG-A 在较大学习率下出现很大的 per-batch loss spike。

右图中 VGG-A+BN 的 band 在中后段更宽, BN 使较大学习率也能有效下降, 因此高学习率曲线更快进入低 loss 区域, 而低学习率曲线下降较慢, 同一步的上下界差距反而变大。相比之下, 无 BN 的曲线更窄, 部分原因是多条学习率曲线都停留在较高 loss 区域。综合最大 band width (18.0730 vs. 5.7247)、final mean loss (2.0057 vs. 1.3629) 和学习率 sweep 准确率, BN 的主要收益是避免失控更新, 使更多学习率设置能够持续下降并进入更低损失区域。

3.4 Gradient Predictiveness and Effective β -smoothness

Loss landscape band 从损失值角度展示了 BN 对训练稳定性的贡献，但 Santurkar 等人 [2] 指出，理解 BN 的优化机制还需要考察梯度本身的变化。一阶优化方法（如 SGD）依赖当前梯度来预测最优更新方向；如果梯度在参数空间中变化剧烈，则当前梯度对下一步的预测性差，优化过程容易出现振荡或失控。

为此，我们在训练过程中逐步测量两个指标。设第 t 步的参数为 θ_t ，梯度为 $g_t = \nabla \mathcal{L}(\theta_t)$ 。优化器更新后参数变为 θ_{t+1} ，对应梯度 g_{t+1} 。定义：

- **Gradient predictiveness**（梯度可预测性）：

$$\|g_{t+1} - g_t\|_2,$$

衡量连续两步之间梯度方向和大小的变化。若该值较小，说明当前梯度对下一步仍具有良好的预测性，优化过程更稳定。

- **Effective β -smoothness**（有效平滑度）：

$$\beta_t = \frac{\|g_{t+1} - g_t\|_2}{\|\theta_{t+1} - \theta_t\|_2},$$

将梯度变化量归一化为参数移动距离的比率。 β_t 越小，说明单位参数扰动引起的梯度变化越温和，即优化景观越平滑。

实验使用 SGD (lr=0.01, momentum=0.9) 在 10,000 张训练子集上训练 10 epoch，每 2 步采样一次。表 8 和图 9 给出了实验结果。

表 8: Gradient landscape statistics (SGD, lr=0.01, 10 epochs, 10K subset).

Model	Mean $\ \Delta g\ $	Max $\ \Delta g\ $	Mean β	Max β
VGG-A	2.80	18.28	63.00	321.82
VGG-A+BN	5.92	17.73	61.86	155.01




图 9: Gradient landscape analysis. Left: gradient predictiveness ($\|g_{t+1} - g_t\|_2$); center: effective β -smoothness; right: training loss. VGG-A shows large early spikes in β -smoothness, indicating a rough landscape that makes the gradient unreliable for predicting the next step.

从实验结果可以得到以下观察。首先, VGG-A 的最大 β -smoothness 为 321.82, 是 VGG-A+BN (155.01) 的两倍以上。这意味着 VGG-A 在训练过程中存在局部区域, 梯度相对于参数扰动变化极为剧烈——这正是导致大学习率下训练失败的根源。BN 将最坏情况下的梯度变化率降低了约一半。

其次, VGG-A+BN 的绝对梯度差 $\|\Delta g\|$ 均值反而更大 (5.92 vs 2.80), 这是因为 BN 使网络能够有效学习, 梯度保持较大幅度; 而 VGG-A 在 SGD lr=0.01 下收敛困难 (final loss 1.17 vs 0.11), 部分步骤的梯度已经很小, 拉低了均值。关键在于归一化后的 β , VGG-A+BN 的均值和最大值均更低, 说明其优化景观整体更平滑。

第三, 从图 9 的时序曲线看, VGG-A 在训练初期 (前 50 步) 出现了显著的 β 尖峰, 对应着优化景观最不稳定的阶段; VGG-A+BN 在相同阶段没有出现类似的极端波动。这与 loss landscape band 的观察一致: BN 的核心收益是抑制训练早期的极端梯度/损失波动, 让优化器能够安全地通过初始化附近的敏感区域。

4 Discussion

Part 1 的结果表明, 在 CIFAR-10 这类小尺寸图像任务上, 一个专门设计的残差 CNN 可以在不依赖预训练模型 (从 0 开始训练) 的情况下达到 96% 以上测试精度。最有效的因素是足够的卷积宽度、SGD + momentum、cosine schedule 和适度 label smoothing。相较之下, 更复杂的激活函数和 focal loss 没有带来收益, 说明模型改进需要结合数据分布和优化设置, 而不是简单堆叠技巧。网络解释性分析 (滤波器可视化、特征图演变和 Grad-CAM) 进一步验证了模型确实学到了从低级边缘到高级语义的层次化特征, 且预测决策基于目标物体区域而非背景噪声。

Part 2 的结果清楚显示 BN 的价值主要体现在优化稳定性上。VGG-A 与 VGG-A+BN 参数量几乎相同, 但 BN 版本在主实验中高 2.91 个百分点, 在高学习率设置下优势扩大到十几个百分点。loss landscape band 说明 BN 减少了极端 loss spike; gradient predictiveness 和 β -smoothness 实验则从梯度角度量化了这一效应——BN 将最坏情况下的有效平滑度从 321.82 降低至 155.01, 使梯度对参数扰动的敏感度下降约一半。这个结论与文献中的认识一致: BN 最初被解释为减轻 internal covariate shift [1], 但更现代的解释强调其对优化景观的平滑作用 [2]; 本项目从 loss band 和梯度平滑度两个维度都直接支持后者。

综合来看, Part 1 和 Part 2 回答的是两个不同层面的问题。Part 1 关注如何组合架构、增强、优化器和正则化来获得高测试精度; Part 2 关注一个归一化层如何改变优化过程。前者说明 residual design 和合适训练 recipe 可以显著提升泛化能力, 后者说明 BN 即使只增加极少参数, 也能改变 loss 曲线形状和学习率鲁棒性。这也是为什么 VGG-A+BN 的绝对精度不及 CifarResNet, 但仍然能很好地支持 BN 有效性的结论。

5 Conclusion

本项目完成了 CIFAR-10 自定义 CNN 训练、系统消融实验、网络可解释性分析、VGG-A BatchNorm 对比实验以及 loss landscape 和梯度平滑度分析。Part 1 best checkpoint 达到 96.59%, 消融实验最高观察精度为 96.85%; Grad-CAM 和特征图可视化验证了网络学到了层次化的语义特征。Part 2 中 VGG-A+BN 达到 90.52%, 明显优于无 BN baseline; gradient predictiveness 和 β -smoothness 实验从梯度角度量化了 BN 对优化景观的平滑效应。整体实验结果相互支撑: 残差

结构、合适正则化和稳健优化策略决定最终分类性能，而 BatchNorm 的核心作用是改善优化条件、降低梯度对参数扰动的敏感度、扩大稳定学习率范围并降低训练失败风险。

参考文献

- [1] Sergey Ioffe and Christian Szegedy. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. In *International Conference on Machine Learning (ICML)*, 2015. <https://arxiv.org/abs/1502.03167>
- [2] Shibani Santurkar, Dimitris Tsipras, Andrew Ilyas, and Aleksander Madry. How Does Batch Normalization Help Optimization? In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018. <https://arxiv.org/abs/1805.11604>
- [3] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. In *International Conference on Computer Vision (ICCV)*, 2017. <https://arxiv.org/abs/1610.02391>